

引导

冯氏结构的特点：可编程、计算和存储分离

操作系统的特征

操作系统的分类

进程

进程和程序

进程状态

进程和线程

调度

CPU调度

CPU资源调度(决策指标)

调度策略

数据

内存管理

内存管理需要满足的目标

碎片

虚拟内存基本思想

基本特征

性能

分页管理

页面替换

Belady现象

CPU利用率与并发进程数的关系

覆盖技术

段

抖动问题thrashing

负载控制

输入输出设备

设备控制器

文件系统

文件

目录

文件和卷

文件基本操作

设计磁盘文件系统的挑战

磁盘文件系统

概述

获取数据

文件存储方式

RAID

FAT文件系统

优缺点

FFS文件系统

特点

目录机构

空闲地址映射和局部性分配

优缺点

NTFS：引入新概念Extents

文件系统布局

备份策略

目录存储格式

硬连接和符号连接的存储格式

虚拟文件系统

磁盘文件系统的镜像

mount系统调用

- open系统调用
- 进程间通信
 - 进程间为什么要通信？
 - 进程间如何通信？
 - 管道模型
 - 消息队列模型
 - 信号
 - 共享内存模型
 - 信号量
 - IPC问题
 - 临界区
 - solutions
 - 忙等待
 - 睡眠和唤醒
 - 消息传递
 - 用户指令与内核如何交互
 - 中断、异常和系统调用的比较
 - 函数调用和系统调用的不同处
 - 中断、异常和系统调用的开销
- 计算机网络系统
 - TCP
 - 存储方式
 - listen函数
 - Remote Method Invoke/Procedure Call模型
 - 反射机制
- 死锁
 - 定义
 - 条件
 - 危害
 - 怎样解决死锁
 - 死锁预防
 - 死锁避免
 - 资源配置状况
 - 银行家算法
 - 死锁检测和系统恢复
 - 非资源死锁问题

引导

冯氏结构的特点：可编程、计算和存储分离

- 1.采用指令和数据存储在一起的结构
- 2.存储器是按地址访问、线性编址
- 3.指令由操作码和地址码组成
- 4.指令在CPU的运算单元处理
- 5.控制流由指令流产生

CPU：执行各种计算机指令的逻辑机器

操作系统的特征

1. **并发**: 同时**存在**多个运行的程序(进程), 需要OS管理和调度
2. **共享**: 互斥共享, 某种**资源只能同时被一个进程独享**; 同时访问: **允**

许在一段时间内由多个进程交替访问

3. **虚拟**: 利用多道程序设计技术, 让每个进程和每个用户**觉得**有一个处理器(CPU)专门为他服务。

4. **异步**: 进程执行不是一贯到底, 而是**走走停停且执行速度不可预知**

命令接口: 联机控制(交互式); 脱机控制(批处理)

程序接口: 一组系统调用命令组成, 用户需要使用这些系统调用来请求操作系统提供服务(如外设、磁盘、内存分配和回收等)

操作系统的分类

单道操作系统: 多个进程按照先来先服务的方式顺序执行(排队系统); 内存中只有一个进程运行且它需要执行完毕(独占内存); 在运行时, 高速CPU会等待低速I/O完成, 限制系统吞吐量

多道操作系统: 内存中**同时存放**多个相互独立的进程; **宏观上并行**(先后开始各自的运行, 但都未运行完毕); **微观上串行**(轮流占有CPU); **资源利用率和系统吞吐量均增大**; CPU、内存、I/O设备**资源分配问题复杂**; 大量进程和数据组织和存放的**安全性和一致性问题**

分时操作系统: **分时技术**: 处理器的运行时间分成很短的时间片; 按**时间片轮流**把处理器分配给各个用户或进程使用; 存在系统延时(银行系统、购票系统等)

实时操作系统: 计算机系统接收到程序请求后**会立即处理**, 并在**严格的时限**; 内处理完成该程序**可靠性和实时性保证较难**; 一般需要**专门设计, 普适性较差**

网络操作系统(5G)

分布式操作系统(云, CDN)

中断: 来自CPU执行指令之外发生的事件(I/O、时间中断), 它与当前程序运行无关

异常: 来自CPU执行指令内部的事件(除0、算术越界等); 它依赖当前程序的运行而且不能被屏蔽
都用于用户态切换至内核态

大内核: 将操作系统的主要功能模块作为整体运行在核心态, 以此来为应用程序提供高性能服务

模块间信息共享->性能优势明显; 程序服务需求增加、接口形式更复杂->功能耦合度高、模块化程度下降, 内核设计庞大且复杂

微内核: 解决操作系统的内核代码难以维护问题, 即将内核最基本功能(e.g., 进程、线程管理)保留, 剩余功能移到用户态执行

降低了内核设计的复杂度; 具有更好的分层和模块化接口; **性能问题!!!!** 频繁的在用户态和内核态切换

进程

程序：包含代码和数据，是由某种程序语言来刻画

可执行文件：CPU指令+其可使用的数据

进程：操作系统为正在运行的程序提供的**抽象**；包括地址空间+执行上下文(这两个由程序指令控制)+环境(由系统调用控制)

“好的”程序抽象：轻量级且隐藏了具体实现；易于使用的接口；可以被实例化多次；易于实现

小细腰结构：易于实现和维护；安全性(攻击点少)；互联网也是这种结构(IP层)

进程和程序

进程是动态的，程序是静态的：程序是有序代码的集合；进程是程序的执行。通常进程不可在计算机之间迁移；而程序通常对应着文件、是静态的并可以复制。

进程是暂时的，程序是永久的：进程是一个状态变化的过程，程序可长久保存。

进程与程序的组成不同：进程的组成包括程序、数据和进程控制块。程序由语句和指令构成。

进程与程序有对应关系：通过多次执行，一个程序可对应多个进程；通过调用关系，一个进程可包括多个程序。

进程控制块PCB：对于任意一个进程，操作系统会维护一个进程控制块来**描述进程的基本信息和运行状态**，进而控制和管理进程(PCB是进程存在的**唯一标志**)

进程镜像：代码段、数据段以及PCB组成

进程的创建和撤销：本质是对PCB的**创建和撤销**

PCB包含的内容：进程在内存中的位置 (page table)；对应的可执行文件在磁盘的位置

哪个用户执行这个进程 (uid)；进程ID号 (pid)；进程运行状态 (运行态、等待态...)；调度信息、保存的内核SP、中断栈信息...

PCB表的大小决定**并发度**

内核为每个进程维护了对应的进程控制块 (PCB)

内核将相同状态的进程的PCB放置在同一队列

进程状态

创建态 (Init)：申请一个**空白的PCB**，并向其中**填写进程信息**，由操作系统为其**分配必需资源**

就绪态 (Runnable)：进程**获得除CPU外的一切所需资源**，一旦得到CPU调度即可运行

运行态 (Running)：进程在CPU上运行，一个核同时只能运行一个

阻塞态 (Waiting)：进程**等待某一事件**而暂停运行

结束态 (Finished)：PCB置位，资源回收

进程挂起：有时需要对进程做分级处理，引入优先级会使某进程等待时间过长而被换至外存

目的：提高处理机效率：就绪进程表为空时，要提交新进程，以提高处理机效率；为运行进程提供足够内存：资源紧张时，暂停某些进程，如CPU繁忙（或实时任务执行）时内存会比较紧张；便于调试：在调试时，挂起被调试进程对其地址空间进行读写。

就绪状态(Ready)：进程在内存且可立即进入运行状态；

阻塞状态(Blocked)：进程在内存并等待某事件的出现；

阻塞挂起状态 (Blocked, suspend)：进程在外存并等待某事件的出现；

就绪挂起状态 (Ready, suspend)：进程在外存，但只要进入内存，即可运行；

激活：把一个进程从外存转到内存

僵尸进程：当子进程被销毁时，会归还从父进程获得的资源，但并非马上就消失掉，遗留下的数据结构

僵尸进程的销毁：子进程的结束和父进程的运行是一个异步过程，即父进程永远无法预测子进程到底什么时候结束；子进程结束后，应通知父进程需要调用wait()系统调用取得子进程的终止状态，销毁其对应的僵尸进程；由于编程错误或者异常（子进程被kill）->僵尸进程；若父进程比子进程更早的结束，则由init进程(1号进程)接管

进程和线程

引入**进程**的目的：更好地使多道程序并发执行，提高资源利用率和系统吞吐量，增加并发程度

引入**线程**的目的：减少程序在并发执行所付出的时空开销，提高OS的并发能力

引入线程后，进程将只作为除CPU外的系统资源的分配单元，线程则作为CPU调度单元（同一地址空间内的上下文切换代价较小）

线程：OS为正在运行的程序提供的**并发性抽象**，它可被理解为**轻量级进程**

线程是进程的一部分，描述指令流执行状态。它是进程中的**指令执行流的最小单元**，是**CPU调度的基本单位**。

一个线程代表一组顺序执行的指令序列 (a.k.a, 任务)；OS可以像对进程一样，创建、挂起、恢复、运行线程；一个线程必须从属于某一个进程，由线程ID、PC、寄存器集合和堆栈组成，是基本的CPU执行单元（它不拥有系统资源）；属于同一个进程的多个线程相互共享进程资源且是互信的(i.e., 线程解耦了并发性和保护性)

进程为什么需要线程？

性能：充分利用**多核CPU**

自然地呈现程序结构：描述了属于同一程序下的**并发任务**；e.g., 更新屏幕、从磁盘获取数据、获取用户输入信息

高响应性：**交互性线程**（处理用户输入输出）与**功能性线程**分离；功能性线程可以在**后台**运行

隐藏慢速的I/O操作：在某个线程处于I/O等待状态时，**其他功能线程可以被调度执行**

- | | |
|--------------------------------|------------------------------|
| • 具有数据段, 代码段, 堆栈段 | ➤ 具有自己的栈 |
| • 至少拥有一个线程 | ➤ 必须从属于某一个进程 |
| • 进程终止→ 资源回收、线程终止 | ➤ 线程终止→ 线程拥有的栈回收 |
| • 进程间通信需要通过OS和数据传递 (e.g., 信号) | ➤ 线程间通信只需通过共享内存 (e.g., 全局变量) |
| • 拥有隔离的内存地址空间 (i.e., 其他进程不能访问) | ➤ 同一进程下的其他线程可以访问自己的栈 |
| • 创建进程和进程间切换会带来较高的系统开销 | ➤ 创建线程和线程间切换不会带来较高的系统开销 |

11

一个进程(PCB): 隔离的内存地址空间; 独立的代码段、数据段和堆栈段; 共享的I/O资源; 权限保护;
一个或多个线程(TCB), 拥有独立的栈、改变CPU寄存器(PC,SP)的取值

PCB中的cr3成员变量描述了进程的页表基地址, lcr(next->cr3)标识加载下一个调度的进程next的页表基地址

用户态程序的本质是使用资源来完成某种功能

系统态程序的本质就是管理资源进而更好地为用户服务

进程: **用户态程序所需资源**的抽象集合(资源分配单位)

线程: **用户态程序提供功能**的抽象集合(CPU调度单位)

纯用户级线程ULT: 线程的管理全部由用户程序完成, 内核部分只对进程管理, 但增加了“线程库”的概念

优点: 线程切换不需要内核模式特权; 线程调用可以是应用程序级的, 根据需要可改变调度算法, 但不会影响底层的操作系统调度程序; ULT管理模式可以在任何操作系统中运行, 不需要修改系统内核, 线程库是提供应用的实用程序。

缺点: 系统调用会引起进程阻塞; 这种线程不利于使用多处理器并行

核心级线程KLT: 线程由OS内核进行管理, 内核给应用程序级提供系统调用, 实现对线程的使用(线程和进程都在用户空间, 线程表和进程表都在内核)

特点: 线程在内核中有保存的信息, 系统调度是基于线程完成的; 可克服ULT的两个缺点, 且内核程序本身也可以是多线程结构的; 线程间的控制转换需要转换到内核模式。

调度

可抢占式资源：OS可以很容易将进程A的某些资源收回，用于其它进程，并且过段时间可以将相等的资源再次分配给进程A (e.g., CPU)

非抢占式资源：OS不能很容易将进程A的某些资源收回，只能等待进程A主动放弃这些资源 (e.g., 读写磁盘内容)

资源调度：进程 (a.k.a., 任务) 拥有资源的时间 (e.g., CPU)

决定进程服务的顺序；僧多粥少 (时分)；抢占式资源；核心是**CPU调度**

资源分配：进程获得**资源的数量** (e.g., 内存)

决定进程可以获得多少资源；狼少肉多 (空分)；非抢占式资源；无线网络是时分和频分

CPU调度：从就绪态任务队列选择下一个使用CPU的任务

磁盘调度：选择下一个对文件或块设备的读写操作

网络调度：选择下一个发送或处理的数据包

内存页替换调度：选择cache中哪个内存页被替换

计算机通过操作系统主要完成**计算、通信和存储**三个方面功能

CPU调度

调度对象：**进程/线程** (i.e., 任务)，例如点击鼠标、网页请求

调度方式：从**就绪态任务队列**选择**下一个使用CPU的任务**

进程调度是非阻塞的过程

从资源角度来看，本质是**交替改变CPU和I/O操作**，分为CPU密集型和I/O密集型任务

从与用户参与度来看，可以分为**批处理**和**交互式**任务(批处理：用户不需要参与，一堆处理，后台自行执行；交互式：需要用户输入等，用户参与，前台处理)

从安全权限角度来看，可以分为**系统级**和**用户级**任务

CPU资源调度(决策指标)

响应时间：用户态程序完成某些功能所需的总时间

初始等待时间：任务第一次被调度的事件 - 到达时间

总体等待时间：线程在就绪态队列中等待的总时间

吞吐量：单位时间CPU完成的任务数

系统开销：完成任务所需的额外资源量(事件、空间)

公平性：每个任务使用CPU的时间或资源量

饥饿度：任务两次被调度之间的等待时间

调度策略

FIFO先来先服务策略：第一个到达的请求CPU的任务获取CPU资源；非抢占式调度

优点：实现简单，调度公平

缺点：任务等待时间取决于任务到来时间，即无法发生抢占操作；头阻塞问题；无法很好地支持交互式任务

SJF最短任务优先策略：试图最小化平均响应时间；使用预测来判断任务长短；可以优化给定任务集合的平均响应时间问题

非抢占式：一旦任务获得CPU后，只有当其完成后才行调度下一个任务

抢占式：若一个任务获得的CPU执行时间少于其所需CPU的执行时间，则发生抢占(执行最短剩余时间优先)

通常使用**红黑树实现SJF**

优点：为每个任务分配相同的CPU资源；较低的平均等待时间；当任务所需执行时间差别较大时，较低的平均响应时间；当任务数不是特别大时，可以很好地支持交互式任务

缺点：设置时间过大越趋近FIFO；过小则导致过多切换

RR时间片轮转算法：分配处理机资源的基本时间单元

优先级调度：每个任务分配一个优先级

多级队列调度：根据任务类型存在多个就绪态任务队列；不同的任务队列可以采用不同的任务调度策略

多级反馈队列调度：类似多级队列，但是是动态的，分层调度，每层使用不同的策略，但是需要考虑的参数较多

实时任务调度：具有延时约束要求；终止时间要求；周期性时间；研究热点

多核任务调度：哪个任务在哪个CPU上运行

数据

bss：未初始化或者初始化为0的全局变量

data：初始化非0的全局变量

rodata：只读数据/局部变量

全局变量：线程共享进程的内存，便于线程间的数据通信

多线程访问数据：共享内存全局变量会出现问题。CPU切换，会导致写的顺序出现差错。线程私有数据不会出现问题。

进程和线程的本质就是**调用主线程**

上下文切换的主要任务：1.切换**进程内存空间(堆栈)**。2.切换**CPU寄存器和指令指针寄存器**。

抢占式调度：包含**时间驱动**和**任务被唤醒**两种形式

内存管理

内存管理需要满足的目标

隔离性：不希望不同的进程状态在物理内存中相互冲突

共享性：希望有选择性的共享某些物理内存，实现高效进程间通信

虚拟化：希望为每个进程提供一种“幻觉”，它可以独占所有物理内存->引入虚拟内存

利用率：希望能尽可能的高效利用有限的物理资源

内存管理的任务：虚拟内存的管理；物理内存的管理；虚拟->物理内存的映射

不同进程的相同用户态虚拟地址会映射到**不同的**物理地址 (**隔离**)

不同进程的相同内核态虚拟地址会映射到**相同的**物理地址 (**共享**)

内核本质也是**ELF文件**

碎片

碎片：在储存分配过程中产生的、不能供用户作业使用的主存里的小分区

碎片整理：通过调整进程占用的分区位置来减少或避免分区碎片

碎片紧凑：通过移动分配给进程的内存分区，以合并外部碎片

条件：所有的应用程序可动态重定位

虚拟内存基本思想

一个或多个进程的程序段、数据段、堆栈段总和可以大于物理存储空间

进程中的各段不必完全装入内存，就可启动进程运行

操作系统定时将暂时不用的信息换出内存

需要时操作系统再将交换区信息换入内存

基本特征

不连续性：物理内存分配非连续；虚拟地址空间使用非连续

大用户空间：提供给用户的虚拟空间可大于实际的物理空间

部分交换：虚拟存储只对部分虚拟地址空间进行调入和调出

性能

有效存储访问时间EAT

$EAT = \text{访存时间} * (1-p) + \text{缺页异常处理时间} * \text{缺页率}p$

分页管理

基本思想：将程序的逻辑地址空间划分成固定大小的页(page)，其大小与内、外存大小，内外存传输速度有关。

页表，多级页表，TLB，反置页表(基于Hash映射值查找对应页表项中的帧号：进程标识与页号的Hash值可能有冲突；页表项中包括保护位、修改位、访问位和存在位等标识)

页面替换

页换入操作：1.寻找一个空闲的物理页

2.发起磁盘块加载请求

3.阻塞当前进程P1

4.上下文切换到新的进程

5.当磁盘块加载完毕后更新页表项 (frame号+标识)

6.将进程P1放回到Runnable队列中

页换出操作：1.寻找页表中所有与其相关的表项 (共享页, COW页)

2.将这些页表项均置为失效

3.清楚TLB表中对应的表项

4.如果需要的话, 将物理内存页的内容写回磁盘块(代码段和只读数据不需要写回)

页面替换算法：

Random: 随机换出一个物理页面 (worst case)

FIFO: 根据页面换入顺序, 换出最早换入的页面

OPT: Belady's algorithm (offline), 换出其未来被访问的时间距离当前最远的页面

LRU: 换出未使用时间最长的页面(利用时间戳进行页面的标识)

LFU: 换出单位时间内最少使用的页面

始终置换算法Clock: 访问页面时, 在页表项记录页面访问情况; 缺页时, 从指针处开始顺序查找未被访问的页面进行置换(形成环形链表; LRU和FIFO的折中)例子如下:

时间	0	1	2	3	4	5	6	7	8	9	10
访问请求		c	a	d	b	e	b	a	b	c	d
物理帧号	0	a	a	a	a	e	e	e	e	e	d
1	b	b	b	b	b	b	b	b	b	b	b
2	c	c	c	c	c	c	c	a	a	a	a
3	d	d	d	d	d	d	d	d	d	c	c
缺页状态						●		●		●	●

驻留页面的页表项	0 a	0 a	1 a	1 a	1 a	1 e	1 e	1 e	1 e	1 e	1 d
	0 b	0 b	0 b	0 b	1 b	0 b	1 b	0 b	1 b	1 b	0 b
	0 c	1 c	1 c	1 c	1 c	0 c	0 c	1 a	1 a	1 a	0 a
	0 d	0 d	0 d	1 d	1 d	0 d	0 d	0 d	0 d	1 c	0 c

Belady现象

现象：采用FIFO等算法时，可能出现分配的物理页面数增加，缺页次数反而升高的异常现象

原因：FIFO算法的置换特征与进程访问内存的动态特征矛盾；被它置换出去的页面并不一定是进程近期不会访问的

CPU利用率与并发进程数的关系

进程数少时，提高并发进程数，可提高CPU利用率

并发进程导致内存访问增加

并发进程的内存访问会降低访存的局部性特征

局部性特征的下降会导致缺页率上升和CPU利用率下降

覆盖技术

原理：一个程序的**代码段或数据段**，按照时间先后来占用公共的内存空间，操作系统可以将程序必要部分(常用功能)的代码和数据常驻内存，可选部分(不常用功能)平时存放在外存(覆盖文件)中，在需要时才装入内存。不存在调用关系的模块不必同时装入到内存，从而可以相互覆盖。

缺点：编程时必须划分程序模块和确定程序模块之间的覆盖关系，**增加编程复杂度**；从外存装入覆盖文件，**以时间延长换取空间节省**。

段

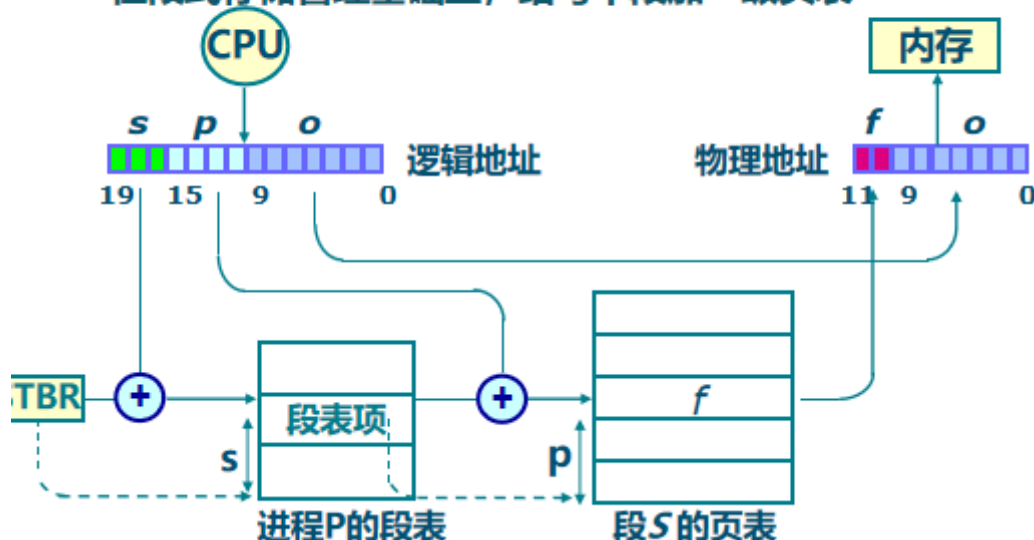
段内连续，段外不一定连续

段表示**访问方式和存储数据**等属性相同的一段地址空间

对应一个连续的内存“块”

段页式存储管理

■ 在段式存储管理基础上，给每个段加一级页表



抖动问题thrashing

抖动：进程物理页面太少，不能包含工作集；造成大量缺页，频繁置换；进程运行速度变慢。

产生抖动的原因：随着驻留内存的进程数目增加，分配给每个进程的物理页面数不断减少，缺页率不断上升。

操作系统需在并发水平和缺页率之间达到一个平衡：选择一个适当的进程数目和进程需要的物理页面数。

负载控制

通过调节并发进程数（MPL）来进行系统负载控制

$\sum WSi$ = 内存的大小

平均缺页间隔时间(MTBF) = 缺页异常处理时间(PFST)

发生抖动怎么办？

杀死某些进程；挂起某些进程；全机重启

输入输出设备

设备控制器

CPU通过**写设备控制器**的寄存器，实现对**控制器下发指令**

CPU通过**读设备控制器**的寄存器，实现对**I/O设备状态查看**

CPU**读写寄存器**相比直接操作硬件要**更标准、简单**

I/O设备的分类：块设备和字符设备

块设备：将**信息存储在固定大小的块中**，每个块**都有自己的地址**，例如硬盘，块大小为4KB且地址是扇区号

字符设备：**发送或接受的是字节流**，不用考虑任何块结构，没有方式寻址，例如鼠标

若I/O设备传输的**数据量较大**(磁盘或打印机), 其设备控制器会设置**数据缓冲区** (类似内存)。只有缓冲区的数据**达到阈值才会真正执行读写I/O设备**

非阻塞I/O模式->轮询等待

设备控制器的寄存器会有**状态标志位**, 通过该值来确定**某个指令操作是否完成**

while (true) {直至状态标志位显示完成}

会**参与进程/线程调度**, 影响**整体系统性能**

异步I/O模式->中断

OS提供一个**硬件中断控制器**

当硬件完成某个任务触发**中断到硬件中断控制器**, 该控制器会**通知CPU**, CPU会**停下当前执行任务去处理中断** (优先级)

软中断 (系统调用, INT xxH) vs. **硬件中断** (中断控制器触发)

DMA技术：CPU对DMA控制器下指令，指定从I/O设备读取多少数据到内存的某个地方，DMA控制器会发指令给设备控制器，后者执行上述读数据任务，待传输完毕，设备控制器会通知

设备控制器**不属于OS**的一部分

每种设备控制器的**寄存器、缓冲区的使用模式以及支持的指令都不同**->OS需要将它们的**差异进行屏蔽**

设备驱动程序属于OS的一部分, 它既**包含面向I/O设备控制器的代码**, 又**包括对OS统一的接口**(能够屏蔽设备控制器的差异)

设备驱动程序的本质是**内核模块**

构建内核模块：1.**头文件部分**：内核模块必须包括以下2个头文件#include<linux/module.h> 和 #include<linux/init.h>

2.定义函数用户**处理内核模块的逻辑**

3.定义一个**file_operations结构**，对于文件系统的操作均需要这一结构进行描述

4.定义**整个模块的初始化函数和退出函数**, 例如在打印机驱动中定义了lp_init和lp_cleanup

5.调用**module_init**和**module_exit**, 分别指向上面的初始化和退出函数module_init(lp_init), module_exit(lp_cleanup)

6.最后调用**MODULE_LICENSE**，**声明一下license**

I/O设备工作要素：

需要一个设备驱动程序(.ko文件)：初始化函数、中断处理函数、设备操作函数；加载设备驱动时, 初始化函数被调用, 并在cdev_map结构中注册该设备 (利用主/次设备号进行查找), 根据主设备号可以获得该设备的驱动程序

需要在/dev目录下创建设备文件：该文件属于特殊的文件系统devtmpfs, 也需要相应的dentry和inode (这里的inode与磁盘文件不同); 磁盘文件的inode指向文件数据, 而设备文件的inode指向设备的驱动程序 (通过主/次设备号在cdev_map中获得)

打开和读写设备文件, 类似磁盘文件操作：文件描述符fd, file结构, path结构 (inode), file_operations结构

中断处理过程：

中断是从**外部设备**发起, 形成外部中断, 外部中断会**到达中断控制器**, 控制器会发送**中断向量**给CPU

每个CPU都有一个**中断向量表(idt_table)**, 里面存放了不同的**中断向量处理函数**

硬件中断处理函数的**统一接口是do_IRQ()**, 它会把**中断向量通过vector_irq映射为irq_desc中断描述结构**

irq_desc中的成员irqaction描述了**用户注册的中断处理函数结构**

文件系统

背景：内存只能暂存数据，如果需要进程结束后数据仍然保存，就需要存储在外部存储中（例如磁盘）

知识（数据）->书籍（文件）->图书馆（磁盘）

文件系统：图书馆书籍管理系统

块：4KB 扇区：512B

文件

元数据：由操作系统添加的信息，包括文件大小、文件创建者、文件修改日期、访问权限等（**inode**、**index node**）

应用数据：用户产生的具体数据

磁盘数据的存储形式

文件创建时必须命名，进程根据文件名访问文件内容

文件名=ascii码 + 和扩展名


目录

绝对路径：从根目录开始到文件

相对路径：从当前工作目录开始到文件

硬连接：将一个文件名映射到某个文件或目录（多个文件绑定，同时修改；相当于文件的另一个路口）

符号连接：将一个文件名映射到另一个文件名（类似快捷方式，符号链接文件存储的是源文件的路径）



文件和目录都有**标号**

文件和卷

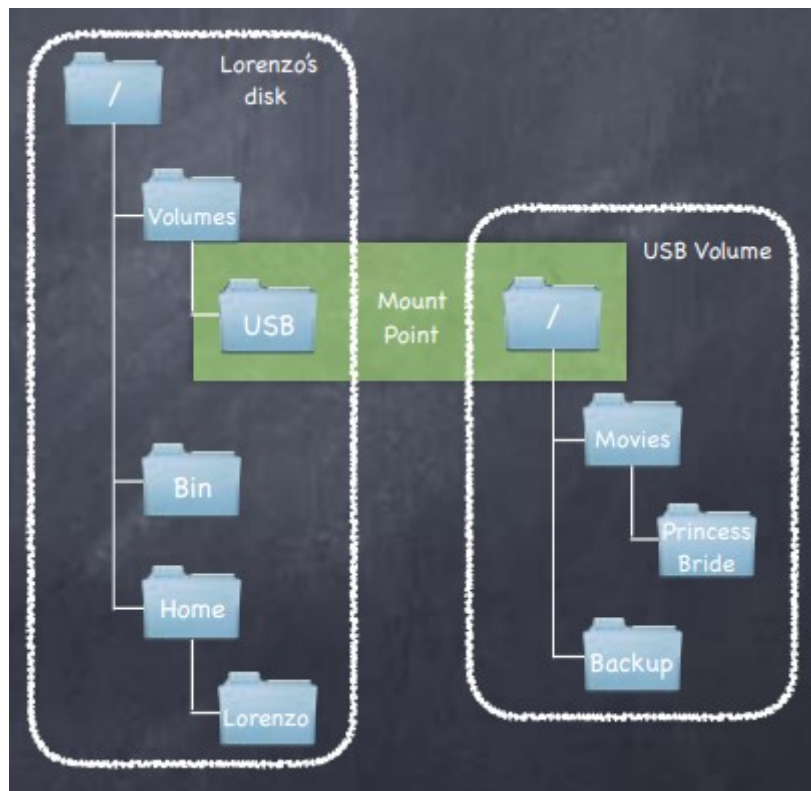
卷：一系列物理资源块形成的逻辑存储设备

挂载：将某个卷和某个文件系统建立连接（usb）

本质：将文件系统中的某个路径与被挂载的卷的根目录建立映射关系

磁盘文件系统

虚拟文件系统



文件基本操作

创建、写、读、删除、在文件末尾添加新内容

本质：将文件名与磁盘块进行映射

fd：文件描述符

操作系统在打开文件表中维护的打开文件状态和信息

作用域是当前进程，所有操作都需要fd

设计磁盘文件系统的挑战

高性能（磁盘的空间仍然有限）

普适性（文件系统需要支持各种类型的文件；大多数文件属于小文件，所以体积不是很大，因此设计的磁盘块不宜过大；对大文件的访问需要实现高效性，即如何快速寻找相关的磁盘块）

持久性（在磁盘上高效地管理和更新用户数据）

可靠性（发生os异常或读写异常时可以保持存储数据不被破坏，或可以很快回复）

（注：目录：会根据文件名找到文件号（Inode=index node）；文件：根据文件号确定所属地磁盘块；好的文件系统一定要让同一文件的磁盘块位于相近的位置？？）

磁盘文件系统

概述

磁盘文件系统<-格式化磁盘

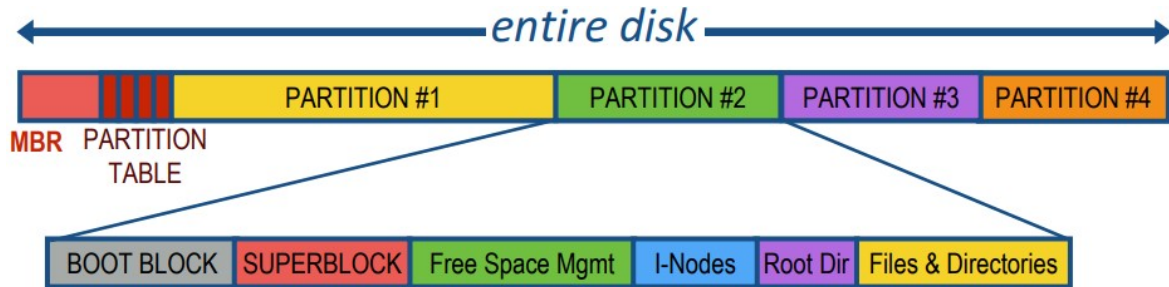
存储在磁盘上

分区方式划分磁盘

0盘0面1扇区为引导扇区MBR (Master Boot Record)

紧跟着MBR的是磁盘分区表

每个分区第一个块是启动块，由MBR填入，系统启动时会执行MBR，会执行每个分区的启动块



获取数据

建立索引：用于定位每个文件的每个磁盘块（一般会按照树形结构存储）

空闲地址映射：提出快速的分配机制（一般会采用bitmap实现）

局部性原则：尽量将相同文件的靠近内容放置在物理相近的磁盘块（便于seek）

文件存储方式

连续分配原则：按创建顺序及大小依次占用磁盘块

优：实现简单，每个文件只需要记录器初始和终止磁盘块；高效，整个文件读写仅需要依次seek操作

劣：容易碎片化，特别是当大量文件被移动或删除时；不适合文件大小频繁变化的情景（编写代码、文档）

链表方式：

优：实现简单，文件的每个磁盘块只需维护指向下一个磁盘块的指针

劣：性能不稳定，特别是随机访问文件中的内容（seek频繁）；空间开销问题，每个磁盘块均需要空间来保存指针

索引方式：

优：创建、插入和删除很容易；没有碎片；支持直接访问

劣：当文件很小时，存储索引的开销；如何处理大文件？

磁盘调度算法

FIFO

最短服务时间优先SSTF

扫描算法SCAN(磁臂在一个方向上移动，访问所有未完成的请求，直到磁臂到达该方向上最后的磁道，也称为电梯算法)

循环扫描算法C-SCAN(当最后一个磁道也被访问过了后，磁臂返回到磁盘的另外一端再次进行)

C-LOOK算法(磁臂先到达该方向上最后一个请求处，然后立即反转，而不是先到最后点路径上的所有请求)

N步扫描(N-step-SCAN)算法(将磁盘请求队列分成长度为N的子队列；按FIFO算法依次处理所有子队列)

双队列扫描FSCAN算法(只将磁盘请求队列分成两个子队列)

RAID

RAID研究目标：通过多个并行组件获得额外的磁盘访问性能，实现多个独立的I/O请求可以并行处理，前提是数据信息存放在不同的磁盘中。

RAID包含了0-5个层，它们具有不同的设计结构。其中共同点是：

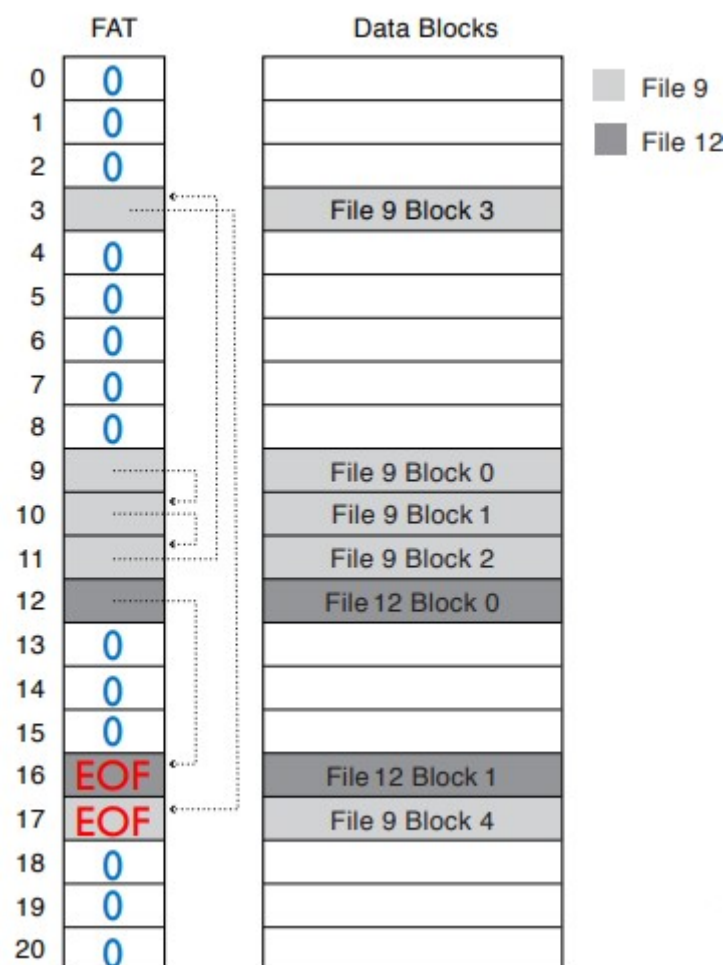
- 1) RAID是一组物理磁盘驱动器，OS将它看成单个。
- 2) 数据分布在物理驱动器阵列中。
- 3) 用冗余的磁盘空间保存奇偶检验信息，使数据具有可恢复性。

RAID的分层特性：RAID0没有用冗余数据提高性能，而是用将数据存储于磁盘阵列中，提高数据访问的并行性；RAID1-5使用冗余数据，但其采用方法不同。

FAT文件系统

70年代，用于DOS和Windows

文件分配表：采用链表形式；将指针部分分离，形成以<key, value, next>结构为表项的链表；需要为每个文件(key)指明其首个磁盘块(value)。



表项为0，没有使用；EOF：某文件的最后一块；每个磁盘块对应一个FAT表项；目录项描述的是一个文件名和其首个磁盘块的关系

目录项->FAT表项->磁盘块

优缺点


优点：实现简单；较少的磁盘碎片；目录和FAT表均在启动时加载到内存中，磁盘块只保存用户数据

缺点：磁盘Seek可能耗时较高；很难提供可靠性；存储目录和FAT表内存开销可能很大（e.g., 1TB (40位) 磁盘, 块大小为4KB (12位), 则需要表项为 $2^{(40-12)} = 2^{28}$, 若每个表项为4 bytes, 则需要 $2^{(28+2)} = 2^{30}$ B)

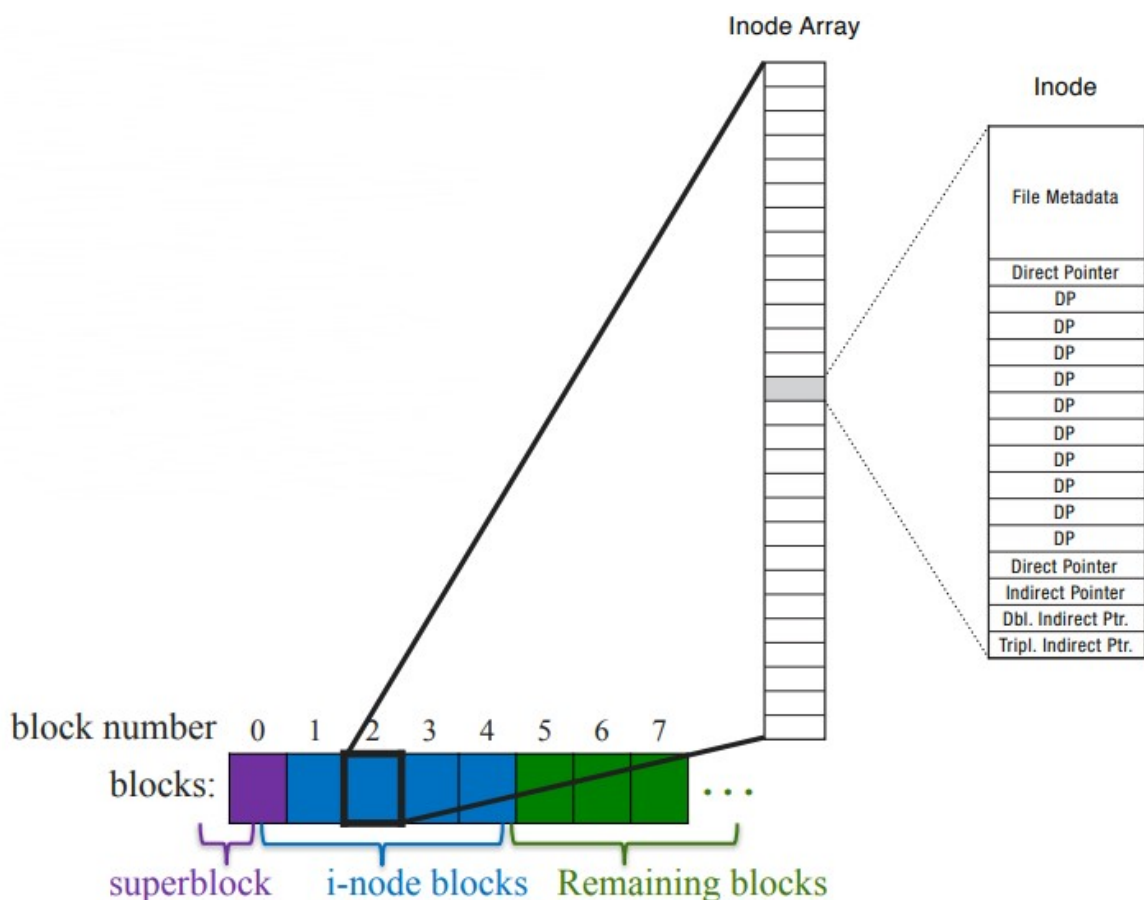
FFS文件系统

80年代, UNIX以及Linux ext2, ext3

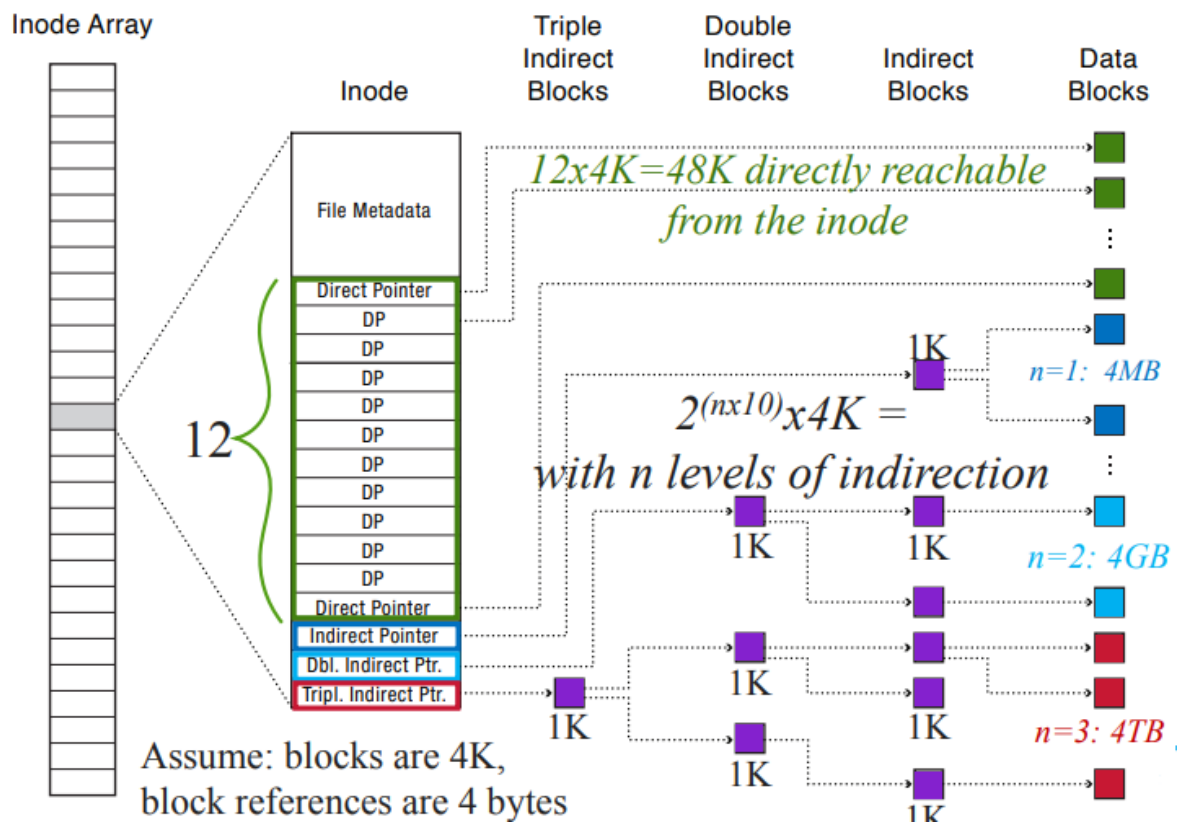
采用**树形-多级索引方式**：每个文件是棵非对称的树，根节点Inode，所有节点大小固定(磁盘块大小4KB)；多级索引可以很好地支持大体积文件和小体积文件；新颖的空间地址映射和局部性分配



超级块：指明文件系统的关键参数(文件系统类型；块大小，inode array的起始位置和长度；空闲块的起始位置)



每一个Inode块是一个Inode Array；Inode array中每个节点是Inode；Inode包含文件的元数据, 12个数据块指针DP以及3个间接指针



File Metadata存储着(类型: 一般文件, 目录, 符号连接等; 文件总大小; 文件所有者 (user id, group id); 权限; 时间: 创建、访问、修改等)

间接指针是多级索引, 适用于大文件的存储; 直接指针用于小文件的存储

为什么简介指针指向1K个数据块(4KB / 4B = 1K)

特点

树形结构->很快地找到所需地磁盘块数据

局部性分配(多级指针)->最小化Seek时间, 可以较好地支持连续读写

固定的结构->易于实现

非对称性: 数据磁盘块不在同一层->支持大体积文件->小体积文件不会产生过多的开销

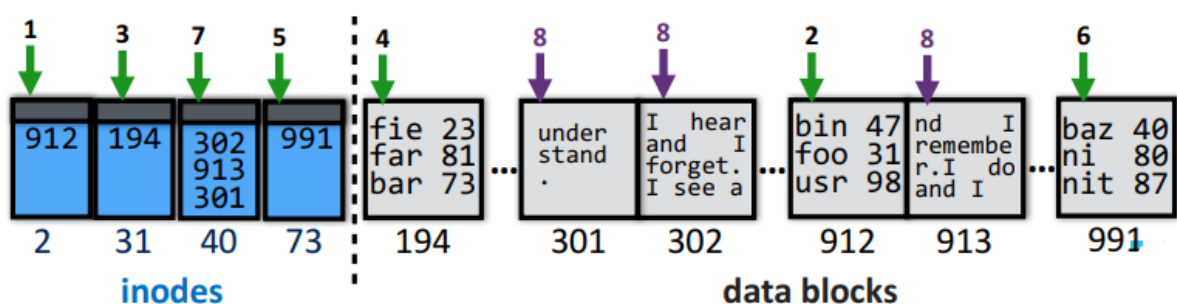
目录机构

采用**线性表结构**

数组项包括: inode号4位; 文件名长度; 文件名

第一个数组项为. 指向自己

第二个数组项为.. 指向上一个inode结点



打开并读取文件/foo/bar/baz

根据**根目录**的inode=2, 找到其所在的**磁盘块912**

根据根目录地址912, 找到**目录foo**的inode=31

根据foo目录的inode=31, 找到其所在**磁盘块194**

以此类推直至找到991块中的**bar文件**inode=40

从inode=40找到该**文件的内容**

空闲地址映射和局部性分配


引入bitmap, 每一位表示一个磁盘块

将磁盘分成块组, 每个块组代表一系列相邻的磁道

均匀地将空闲bitmap和inode array分发给这些块组, 并且每个块组均具有一份超级块的拷贝

在当前目录下, 若创建一个新目录。FFS会将当前目录视为新目录地父目录并为其分配一个磁盘块

若创建文件, 则在当前磁盘块内找一个空闲inode, 根据bitmap将数据徐徐放置在空闲数据块内



优缺点

优点: 可以很好地支持大体积和小体积文件; 实现了局部性放置; 固定地字段格式使得实现较为简单

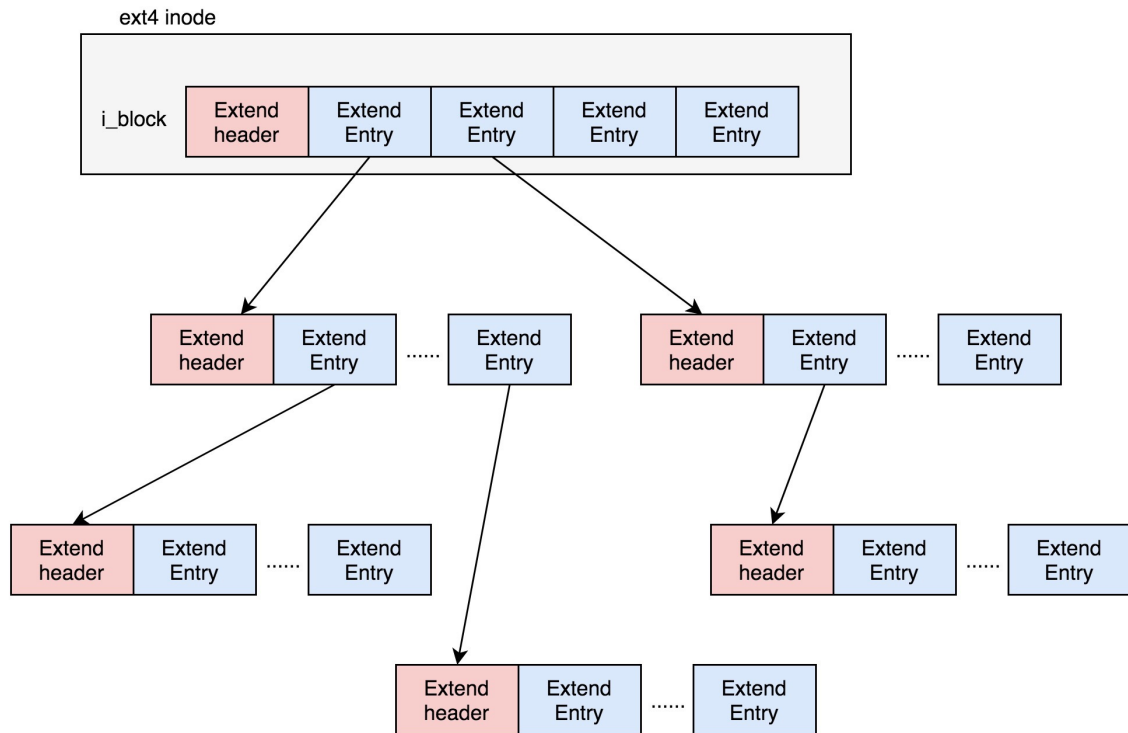
缺点: 不太适合体积极小地文件(tiny file), inode 可能比有效数据量还大, 空间利用率低; 需要预留10%-20%磁盘空间给块组, 实现局部性放置

NTFS: 引入新概念Extents

extents动机: 加入一个文件128M, 磁盘块4KB, 则需要32K个块; 若使用FFS, 需要2级间接指针; 数据块的位置可能过于分散, 导致seek时间比较长; extents可以用来存放连续的块, 树形结构:

header+entry

其中entry类型为：ext4_extent(数据)和ext_extent_idx(索引)



头部表明：**entry最大128M？！**

数据中为什么是低32位高16位？

根节点只有4个entres，每个entry只想一个数据或索引

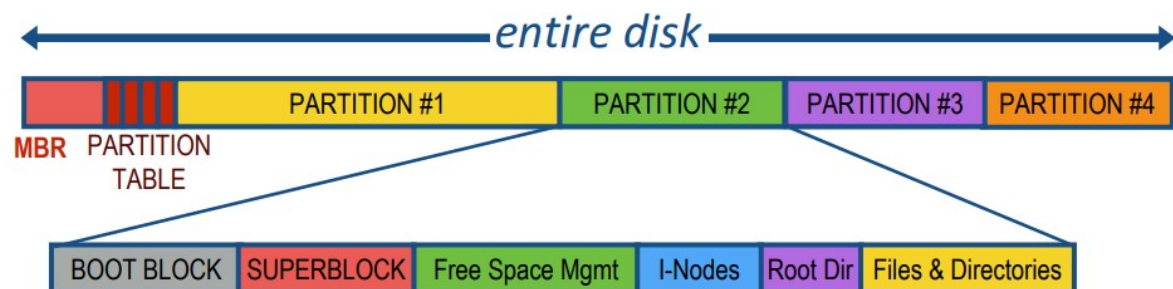
数据extent，叶子结点，每个entry指向了一篇连续的数据块，**最大128M**

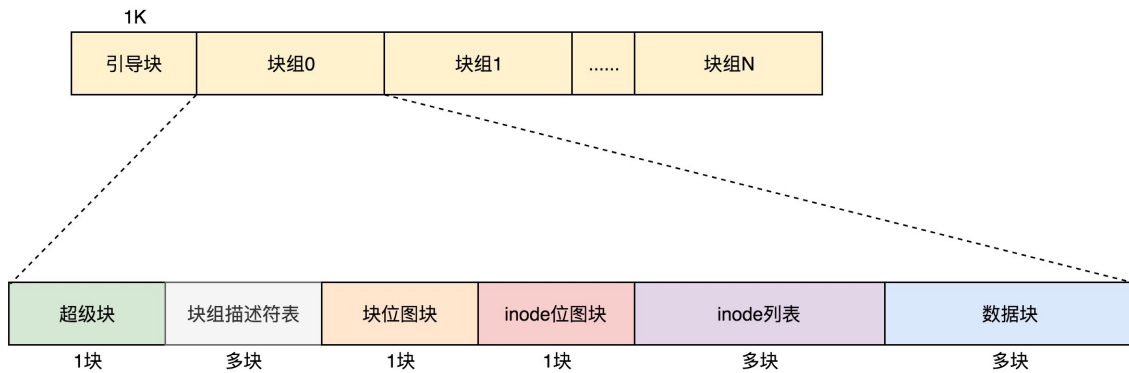
索引|extent，指向另一个数据或者索引|extent

head: 12B entry: 12B

索引|extent 的整体大小为4K

文件系统布局





为什么是128MNB：位图bitmap占1块描述4KB，4KB等于32K个数据块(bitmap 1位表示1个数据块)，所以32K个数据块存储128MB的大小

描述块组的数据结构(局部信息)：块组的块位图，inode位图，inode列表，数据块列表都有相应的成员变量

块组描述符表(全局信息)

超级块(整个文件系统的信息，全局信息)：inode总数, 块总数, 每个块组的inode数目, 每个块组的数据块数目

全局信息必须备份，这会产生冗余，采用何种备份方式？


备份策略

超级块(通常所占内存不多)：每个块组都备份；sparse_super模式：副本只存在块组索引为0、3、5、7的整数幂

块组描述符表(所占内存较多)：每个块都备份(狼粪，限制文件系统大小)；**sparse_super模式(限制文件系统大小)：**一个块组最大128MB，若给定块组数目为N，则文件系统大小为128N；**meta block group模式：**将块组进行再次分组，64个块组为一个元块组，1个元块组的描述符表最多64项；每个块组备份自己的元块组描述符表，一般采用3个备份，分别为第一块、第二块以及最后一块

目录存储格式

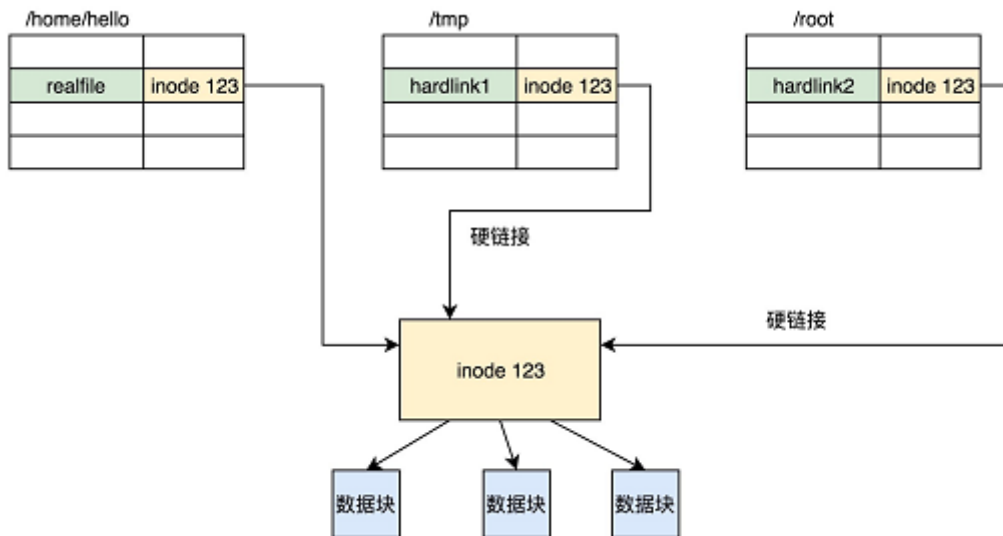
如果inode中iflags设置为EXT4_INDEX_FL：目录的块组织形式将从链表形式变为Hashed Tree结构



硬连接和符号连接的存储格式

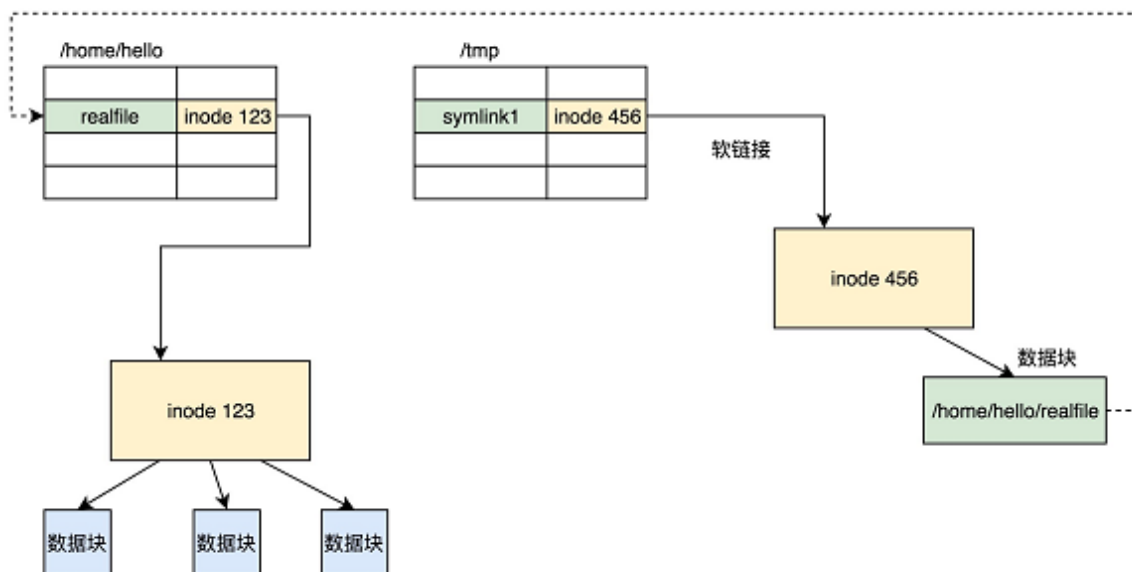
硬连接：与原始文件共用一个inode

inode不能跨文件系统->硬链接不能跨文件系统



符号连接：具有独立的inode

访问符号链接文件，其实是访问指向的另一个文件，可跨文件系统



虚拟文件系统


目的：对所有不同文件系统的 抽象

功能：记录可用文件系统类型；建立设备与文件系统的关联；实现面向文件级的通用性操作；将对特定文件系统的操作影射到物理文件系统中

功能：提供相同的文件和文件系统接口；管理所有文件和文件系统关联的数据结构；高效查询例程, 遍历文件系统；与特定文件系统模块的交互。

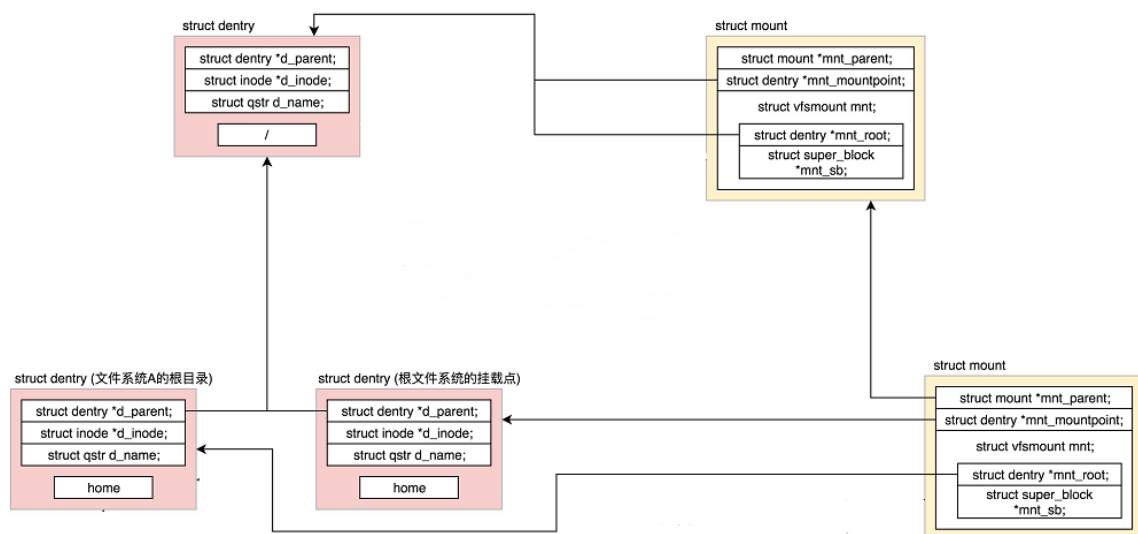
gxI的ppt写了两次功能，后面的应该比较靠谱

磁盘文件系统的镜像



mount系统调用

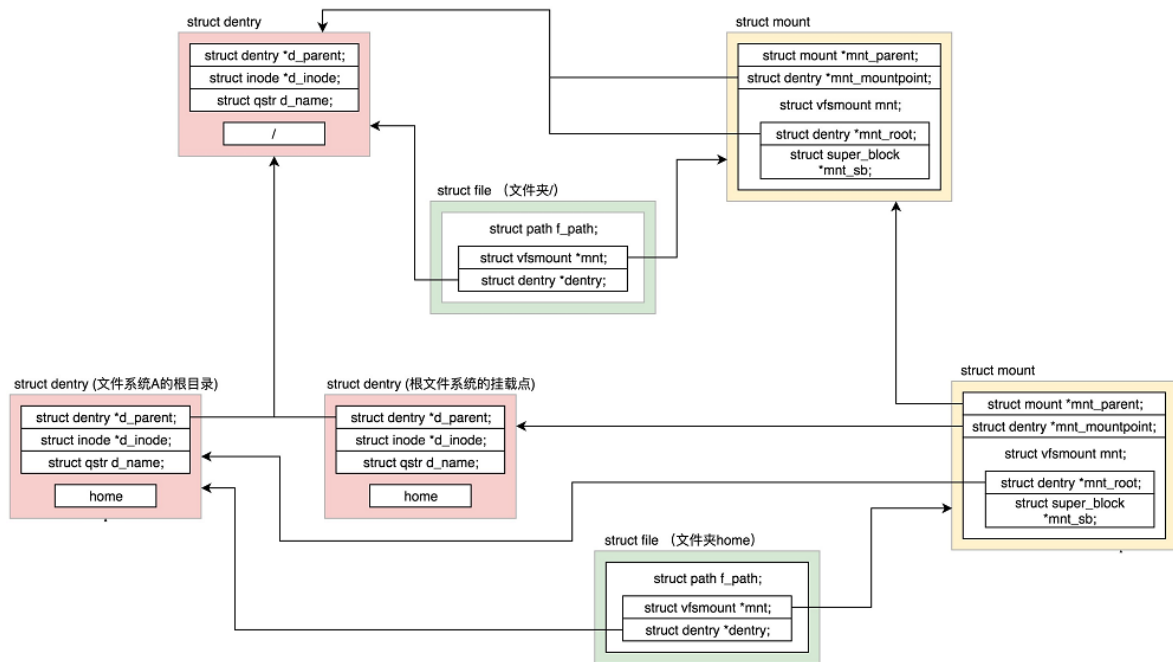
磁盘文件系统：需要首先要挂载文件系统，且必须在内核中注册



将磁盘文件系统A的根目录挂载到虚拟文件系统/home:

这里注意文件系统A的根目录和根文件系统的挂载点, 它们内容相同, 但是属于不同的内存空间 (原因是可以有其它的文件系统挂载到/home上, 此时用到的是挂载点那个内存, 当然前提是该挂载点与A的根目录unmount)

open系统调用



进程的task_struct有个指针成员, 类型是files_struct结构体; file_struct中存在**文件描述符表**, 每一项是 `<struct file*, in/out>` 实质就是fd

sys_open->do_sys_open->do_filp_open 创建struct file结构

->fd_install (fd, f) 创建文件描述符表项 (关联file和fd)

do_filp_open 会初始化struct nameidata, 即解析待打开文件的路径, nameidata中存在**关键成员 struct path**, 与文件系统建立连接

task_struct->files_struct (fd) ->file (fd与映射)->path (磁盘文件系统):

vfsmount (虚拟与磁盘文件系统映射) + dentry (inode)->文件读写操作

进程间通信

进程通信是进程进行通信和同步的机制

直接通信: 进程必须正确的命名对方

通信链路的属性: 自动建立链路; 一条链路恰好对应一对通信进程; 每对进程之间只有一个链接存在; 链接可以是单向, 但通常为双向的

间接通信: 通过操作系统维护的消息队列实现进程间的消息接收和发送

通信链路的属性: 只有共享了相同消息队列的进程, 才建立连接; 连接可以是单向或双向; 消息队列可以与多个进程相关联; 每对进程可以共享多个消息队列。

阻塞、非阻塞和异步通信见**问题PDF**

进程间为什么要通信?

数据传输 (如web服务、进程查询数据库): 一个进程需要将它的数​​据发送给另一个进程

事件通知 (如进程终止时要通知父进程): 一个进程需要向另一个或一组进程发送消息, 通知它们发生了某种事件

资源共享 (互斥和共享): 多个进程之间共享同类资源

进程控制 (如debug程序代码): 有些进程希望完全控制另一个进程的执​​行, 即能够拦截另一个进程的陷入和异常, 并能够及时知道另一个进程的状态改变

进程间如何通信?

单机:

管道模型 进程->内存文件系统(pipe对象)->进程

消息队列模型 进程->内存文件系统(消息队列对象)->进程

信号 进程->OS内核->进程

共享内存模型(同步和互斥) 进程->映射到相同的物理内存->进程

管道模型**消耗额外内存最多!!**

多机:

socket机制

RPC机制

管道模型

进程间基于内存文件的通信机制

类比于项目开发

匿名管道(用完即销毁)和**命名管道**(以文件形式出现)

问题: **通信频率高、通信量大**(缓冲区有限)

消息队列模型

消息队列是由操作系统维护的以字节序列为基本单位的间接通信机制

类比于邮件: 需要对消息格式进行定义; 进程间发送消息采用固定内存大小的数据单元 (i.e., 消息体)

消息队列的操作十分程式化(**目前使用度不高**)

信号

进程间的软件中断通知和处理机制

OS内核与进程之间的通信模式; 一种抽象的数据类型(由一个整形变量和两个原子操作组成)

信号触发的**动机**：内核发现一个系统事件，例如**除0错误或子进程退出**；一个进程调用**kill命令**, 请求OS发送信号给目标进程，例如调试、挂起、恢复或超时等等

信号**接收的机制** (进程收到内核发送的信号)：忽略信号；终止本进程；用一个定义的用户态信号处理函数去捕捉信号

共享内存模型

管道模型、消息队列模型以及信号都是**端到端且数据传输量较小**的IPC, 有些情形需要**多进程协作, 且数据交换量较大**->**共享内存模型**

每个进程有**独立的虚拟内存空间**，映射到不同的物理内存中，即**不同进程访问同一虚拟内存**，本质访问的**物理内存不同 (隔离性)**

如果每个进程拿出一块虚拟内存, 映射到相同的物理地址, 这样一个进程写入的东西, 另一个进程就可以读出, 不需要发送多个消息

类似于进程内的多线程，需要**同步和互斥机制(信号量)**

信号量

是被保护的整型变量，只能由PV修改，且PV是原子操作

P操作->**申请资源操作**(资源量减)

V操作->**归还资源操作**(资源量加)

联合体中val = 共享资源总量

IPC问题

临界区

临界区：进程中访问临界资源的一段需要互斥执行的代码

进入区：检查可否进入临界区的一段代码；如可进入，设置相应"正在访问临界区"标志

退出区：清除"正在访问临界区"标志

剩余区：代码中的其余部分

访问规则：空闲则入；忙则等待；有限等待；让权等待(可选)

solutions

忙等待；睡眠和唤醒；消息传递

忙等待

设计规则：设置一个全局变量来存储CR的状态；进程在进入CR之前检查这个变量

方法：锁变量；严格的交替；Peterson的解决方案；TSL指令(实现自旋锁)

锁：一个抽象的数据结构；一个二进制变量(锁定/解锁)；锁被释放前一直等待，然后得到锁；使用锁来控制临界区访问

优点：解决了两个进程之间的互斥问题

缺点：浪费CPU时间；困难的编程；有可能引起优先倒置问题的风险吗

睡眠和唤醒

设计规则：操作系统提供“原子作用”机制，一种特殊的系统调用；被阻塞的进程将休眠，直到它被唤醒；CPU不浪费，互斥和同步都可以通过这个机制来解决。

方法：简单的睡眠唤醒解决方案；**信号量解决方案**；监控解决方案

管程

组成：一个锁(控制管程代码的互斥访问)；0或者多个条件变量(管理共享数据的并发访问)

条件变量

条件变量是**管程内的等待机制**：进入管程的线程因资源被占用而进入**等待状态**；每个条件变量**表示一种等待原因，对应一个等待队列**

Wait()操作：将自己阻塞在等待队列中；唤醒一个等待者或者释放管程的互斥访问

Signal()操作：讲等待队列中的一个线程唤醒；如果等待队列为空，则等同空操作

消息传递

设计规则：信号量机制依赖于CPU，在分布式环境下，这种机制是无用的；所有这些方法都是为互斥和同步而设计的，流程间的一般信息传递需要更简单有效的机制

关键问题：稳定性:避免数据/信息丢失；一致性:确保目标是正确的；效率:统一消息格式和传输事务

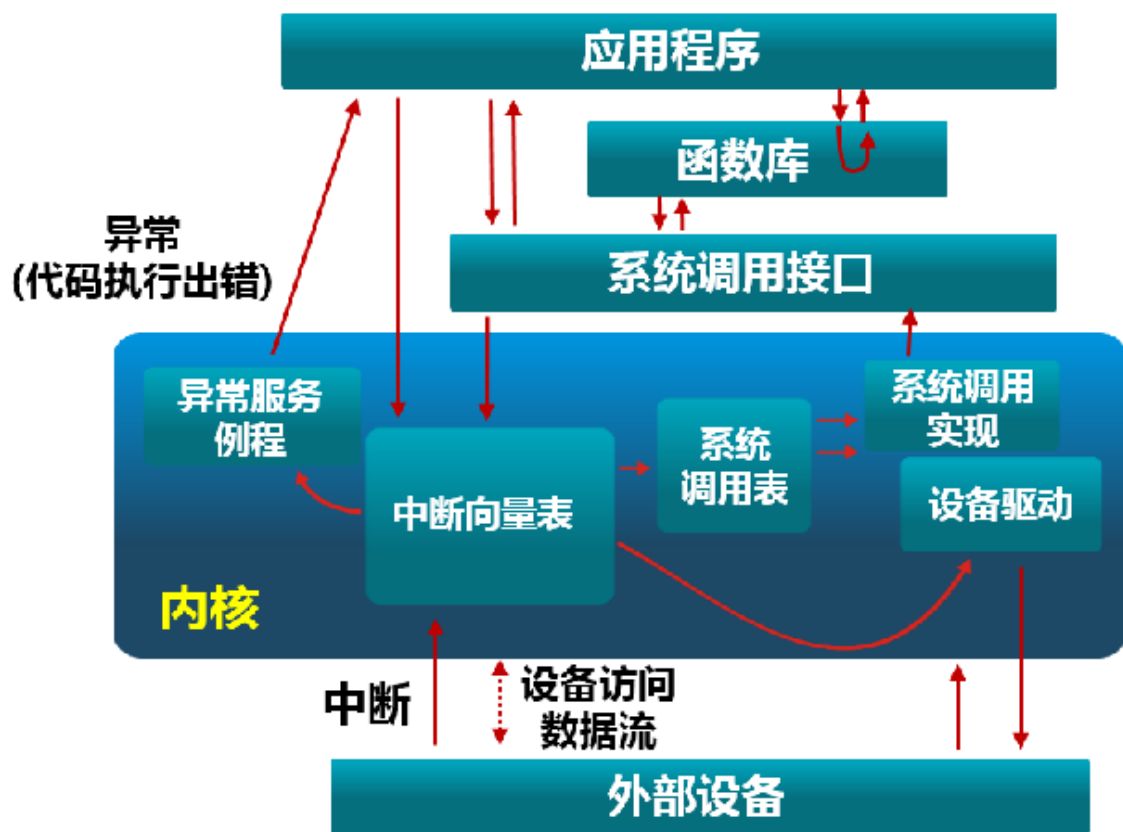
方法：简单的消息传递:发送和接收原语；邮箱:由OS支持；会合:没有中间缓冲

用户指令与内核如何交互

系统调用：应用程序主动向操作系统发出的服务请求

异常：非法指令或者其他原因导致当前指令执行失败

中断：来自硬件设备的处理请求



中断、异常和系统调用的比较

源头：

中断：外设

异常：应用程序意想不到的行为

系统调用：应用程序请求操作提供服务

响应方式：

中断：异步

异常：同步

系统调用：异步或同步

处理机制：

中断：持续，对用户应用程序是透明的

异常：杀死或者重新执行意想不到的应用程序指令

系统调用：等待和持续

函数调用和系统调用的不同处

系统调用：INT和IRET指令用于系统调用(系统调用时，堆栈切换和特权级的转换)

函数调用：CALL和RET用于常规调用(常规调用时没有堆栈切换)

中断、异常和系统调用的开销

超过函数调用

开销：引导机制；建立内核堆栈；验证参数；内核态映射到用户态的地址空间(更新页面映射权限)；内核态独立地址空间(TLB)

计算机网络系统

TCP

TCP是**面向连接**的

TCP提供**可靠交付**, 无差错、不丢失、不重复

TCP面向**字节流**

TCP可以提供**流量控制和拥塞控制**

建立连接: 为了客户端和服务端建议一定的数据结构维护双方交互的状态

双方的状态符合TCP协议的规则, 就认为连接存在, 否则连接断开

流量控制和拥塞控制就是根据收到的对端数据包, **调整两端的数据结构状态**

存储方式

大端存储: 高位字节存放在内存的低地址端, 低位字节存放在内存的高地址端(便于强制转换)

小端存储: 低位字节存放在内存的低地址端, 高位字节存放在内存的高地址端(便于判断符号位)

TCP/IP协议规定网络字节顺序采用大端模式进行编址

listen函数

inet_csk函数的作用是将**sock指针**强制转换成**inet_connection_sock指针**

其**本质**是: tcp_sock结构第一个成员为inet_connection_sock对象,
inet_connection_sock结构第一个成员为inet_sock对象,
inet_sock结构第一个成员为sock对象, 而初始化套接字时
sock *sk其实指向的是tcp_sock对象 (**TCP套接字**)

Remote Method Invoke/Procedure Call模型

传统的socket编程

反射机制: 计算机程序在运行时可以访问, **检测和修改**它本身状态或行为的一种能力;

在面向对象的编程语言中, 反射允许在编译期间不知道接口(类)的名称, 字段、方法的情况下在运行时检查类、接口、字段和方法。

反射机制

静态编译: 在**编译**时确定类型, 绑定对象

动态编译: **运行时**确定类型, 绑定对象, 可以**降低类之间的藕合性**

动态编译在Web服务中的**优点**: 当更新web服务时, 若使用静态编译则需要把整个程序重新编译一次才可以实现功能的更新, 而采用反射机制可以不用卸载, 只需要在运行时才动态的创建和编译, 就可以实现该功能。

缺点：相对于静态编译**其响应时间会慢, 影响性能**

死锁

定义

一个进程集合，集合中的任何进程都在等待集合中的另一个进程的事件被执行完。

这种状态被称为死锁

条件

互斥资源分配：这种资源不能被多个进程分享

进程**持有一些资源并等待一些资源**，它被阻塞，直到请求得到满足。

持有的资源不能被操作系统剥夺，**只有它的主人可以释放它。**

循环等待序列：这个序列中的每个进程都在等待它的邻居释放一些资源，这个序列是循环的。

危害

死锁进程集将永远不会被激活，该状态集持有的资源将永远不可用。

不合理的资源分配机制可能导致死锁。

怎样解决死锁

死锁预防：OS定义了一些约束规则，限制了**进程的资源请求和分配**；约束规则将破坏死锁的条件

死锁避免：操作系统**分析资源分配的现状**，尝试以**安全的方式**分配资源

死锁检测和系统恢复：一个**特殊的进程负责死锁检测**；死锁进程将被**杀死**，持有的资源将被释放。

鸵鸟政策(不理睬)：死锁是一种低概率事件；对低概率事件不做任何处理。

死锁预防

假脱机机制：虚拟共享资源。

资源分配预测：在一次分配中满足一个进程的所有资源需求，否则该进程将被**阻塞**，直到所有需要的资源都可用为止。

资源保护：对死锁进程的资源进行保护，并将资源分配给其他进程。

标记的资源序列：为每种资源分配类型ID，进程必须按升序/降序请求资源。

死锁避免

资源配置状况

安全状态：存在一个合理的资源分配顺序，使所有进程正常运行并结束。

不安全状态：无法找到安全的资源分配顺序，以避免死锁。

安全状态一定没死锁，不安全状态不一定是死锁。

银行家算法

简单条件：

记录资源的最大需求和所有流程的当前分配状态。

模拟：将资源分配给一个进程，并检查所有进程是否可以正常运行以结束。

如果找到了安全的分配序列，就可以将资源分配给这个进程，否则就不能将资源分配给这个进程。

复杂条件：

使用矩阵和向量描述资源分配状态。

仿真：矩阵运算。

按照以下步骤检查所有资源请求。

步骤1：检查“请求矩阵”中的行，并尝试找到小于(可用资源)的行。

“请求矩阵”中的所有行都大于A，这意味着系统处于死锁状态。

可以满足此行所指示的流程请求。

步骤2：将资源分配给选择流程。

将此过程标记为“结束”，释放被此过程占用的资源，更新A。

步骤3：循环执行步骤1和步骤2，直到所有进程都标记为“end”。

步骤4：如果所有进程都被标记为“end”，这意味着资源请求是安全的，可以执行，否则请求就是不安全的，不能执行。

如果能够分配则系统会处于安全状态，如果无法分配，系统将等待/或者是不安全状态，总之不会死锁

死锁检测和系统恢复

检测：

使用图、集、向量和矩阵作为数据结构，记录资源分配的状态，并尝试查找循环等待状态；讨论死锁检测算法。

恢复：

资源保护：对死锁进程的资源进行保护，并将资源分配给其他进程。

回溯：设置进程中的检查点，当检测到死锁时，进程将回溯到检查点。

进程终止：直接终止进程。

非资源死锁问题

两阶段加锁：对需要修改的数据：先请求加锁，再修改数据；若有一个数据已加锁，进程则释放所有加锁的记录。

通信死锁：通信中多个进程发送信息，但需要阻塞当前进程等待对方回复。若发送信息丢失，则死锁。

例如：分布式系统中的通信问题

解决办法：超时中断；

活锁：进程没有死锁，但却无法运行下去，只是在不断的重复尝试，如冲突检测。

进程饿死：由于条件限制使有些进程请求永远无法得到服务，进程被饿死。从饿死进程角度看，像是发生了死锁。